

能碳平台 AGC 回路自适应整定技术方案

—— 基于过程模型辨识（FOPDT）与强化学习（PPO）的 PID 参数自整定

项目	内容
适用范围	工业能碳智控平台「AGC / PID 控制」模块
主实现文件	<code>frontend/src/components/PidControlView.vue</code>
算法库	<code>frontend/src/utls/rl.js</code> （PPO）、 <code>frontend/src/utls/control.js</code> （PID / EKF）
文档版本	v3.0（2026-09-18）
本次修订	全量公式改为 LaTeX 排版；新增第 2 章「变量与符号总表」逐项解析

目录

- 1. 一句话结论
- 2. 变量与符号总表
- 3. 问题定义：PID 整定到底难在哪
- 4. 总体架构：Dyna 三路闭环
- 5. 第一层：状态估计（二维增广卡尔曼滤波）
- 6. 第二层：过程模型辨识（FOPDT）
- 7. 第三层：模型内环境（rollout 推演）
- 8. 第四层：PPO 策略优化
- 9. 安全落地机制
- 10. 方法选型论证：在线 / 离线 / 基于模型
- 11. 代码与文件清单
- 12. 参数速查表
- 13. 验证记录
- 14. 已知局限与后续改进
- 15. 术语表（专有名词解释）

1. 一句话结论

不在真机上学，在「从真机数据蒸馏出来的过程模型」里学。

真机数据只负责把环境压缩成一个可无限次查询的差分方程；强化学习在这个方程里以毫秒级速度做几万次「动作 → 反馈」试错；真机只负责最终验收。这被称为 **Dyna 架构**（1991, Sutton）：真实经验、模型学习、规划（想象试错）三条并行。

学习需要的从来不是「真实环境这个物理实体」，而是「动作 → 后果」的因果反馈。只要模型能给出下一拍会发生什么，反馈就成立。

2. 变量与符号总表

本章是全文档的符号索引。每个符号给出：数学记号 / 中文名 / 物理含义 / 量纲与单位 / 典型取值范围 / 代码中的变量名 / 来源。

记号约定：上标 $\hat{\cdot}$ （预测/先验）、 $^+$ （更新/后验）、 $\tilde{\cdot}$ （估计值）、 $\sim$ （随机量）。

2.1 物理量与实时信号

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
y	被控量 / 过程变量 PV	传感设备实测的原始读数（含噪声）	与测点同（℃、kPa、m ³ /h...）	依测点	<code>ptsRaw[].v</code> 、 <code>liveOf(senId)</code>
z	观测值	卡尔曼滤波的观测量，即本拍 y	同 y	同 y	<code>y</code> （ <code>kf.step</code> 入参）
T	被控量真值	去掉传感器噪声后的 真实 被控量	同 y	同 y	<code>est.t</code> （EKF 输出）、 <code>r.ptsF[].v</code>
$\hat{T}$	真值估计	EKF 对 T 的后验估计，即滤波输出 $\tilde{y}$	同 y	同 y	<code>est.t</code>
u	操纵量 / 调节量 MV	PID 输出写回可调设备的设定值	与设备同（Hz、%、开度...）	$[u_{min}, u_{max}]$	<code>r.uNow</code> 、 <code>curSp(adjId)</code>
u_{eff}	生效中的操纵量	考虑纯滞后后， 此刻真正作用在被控对象上的历史 u	同 u	同 u	<code>uEff</code> （tick / rollout）
r_s 或 SP	设定值 / 目标	期望被控量达到的值	同 y	人工给定	<code>targetOf(senId)</code> 、 <code>sp</code>
e	偏差 / 误差	$e = SP - \hat{T}$ ，控制的基本驱动量	同 y	可正可负	<code>const e = sp - est.t</code>
Δe	偏差增量	$\Delta e_k = e_k - e_{k-1}$ ，反映变化趋势（近似微分）	同 y	小量	<code>de</code>
d	隐藏扰动	传感器 测不到 的未建模动态（开门、温漂、负荷突变）	同 y / 拍	随机游走	<code>d</code> （rollout）、 <code>est.d</code> （估计）
$\hat{d}$	扰动估计	EKF 增广状态估计出的扰动	同 d	同 d	<code>est.d</code>
k	采样序号	第 k 个采样拍	无量纲整数	$0, 1, 2, \dots$	循环变量 k
Δt 或 dt	采样周期	相邻两拍的真实时间间隔	秒 s	默认 1 s	<code>m.dt</code>
$scale$	幅值尺度	被控量的典型幅值，用于 量纲归一化	同 y	> 0	<code>r.scale</code>
$uRange$	调节量程	$u_{max} - u_{min}$ ，动作幅度的归一化基准	同 u	> 0	<code>uRange</code>
$uMaxAbs$	调节量上界模	$\max(u_{max} , u_{min})$ ，功耗归一化基准	同 u	> 0	<code>uMaxAbs</code>

关于 **scale** 的重要性：所有进入神经网络的量、所有噪声协方差、所有奖励项，都除以 **scale**（或 **uRange**）再使用。这使得同一套超参数对「几百℃的炉温」和「0.4 MPa 的压力」都成立，也是滤波与训练能稳定收敛的前提。

2.2 过程模型参数（FOPDT）

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
τ	时间常数	一阶惯性环节响应到 63.2% 所需时间；越大越迟钝	秒 s	1 ~ 600 s	<code>m.tau</code>
θ	纯滞后 / 死区时间	动作发出到被控量 开始 响应的等待时间	秒 s	0 ~ 300 s	<code>m.theta</code>

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
d	纯滞后拍数	$\theta = d \cdot \Delta t$, 离散意义上的滞后步数	拍 (整数)	0 ~ 60	<code>m.delay</code>
K	静态增益	稳态下单位调节量引起的被控量变化 $K = \Delta y / \Delta u$	$[y]/[u]$	任意正/负	<code>m.G</code>
a	自回归系数	$a = e^{-\Delta t / \tau}$, τ 的离散表达	无量纲	$0 < a < 1$	<code>m.a</code>
b	控制增益	$b = K(1 - a)$, K 与 a 的复合表达	$[y]/[u]$	任意	<code>m.b</code>
c	工作点偏置	模型在原点处的不平衡量 (含恒定扰动与坐标偏移)	同 y	依工况	<code>m.c</code>
$G(s)$	传递函数	连续域 FOPDT 模型	—	—	不直接使用

三者关系 (离散 $\leftrightarrow$ 物理):

$$a = e^{-\Delta t / \tau}, \quad b = K(1 - a), \quad \tau = -\frac{\Delta t}{\ln a}, \quad K = \frac{b}{1 - a}, \quad \theta = d \Delta t$$

2.3 卡尔曼滤波变量

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
$\mathbf{x}$	状态向量	$\mathbf{x} = [\mathbf{T}, d]^\top$, 二维增广状态	混合	—	<code>st ([t, d])</code>
$\mathbf{x}^-$	先验状态	时间更新后、观测更新前的预测	混合	—	局部 <code>tPre</code>
$\mathbf{x}^+$	后验状态	融合观测后的最优估计	混合	—	<code>this.st</code>
$\mathbf{P}$	状态协方差	估计不确定度, 2×2 对称阵	平方量纲	正定	<code>this.P</code>
$\mathbf{F}$	状态转移矩阵	$\begin{bmatrix} a & 1 \\ 0 & 1 \end{bmatrix}$	无量纲	—	内联展开
$\mathbf{H}$	观测矩阵	$[1 \ 0]$, 只观测量到 $\mathbf{T}$	无量纲	—	内联展开
$\mathbf{Q}$	过程噪声协方差	$\text{diag}(q_T, q_d)$, 认为状态自身会随机漂移	平方量纲	> 0	<code>qT, qd</code>
$\mathbf{R}$ 或 $\mathbf{r}_v$	测量噪声方差	传感器的不可信程度	平方量纲	> 0	<code>rv</code>
q_T	真值过程噪声	$(0.005 \cdot \text{scale})^2$	$[y]^2$	—	<code>qT</code>
q_d	扰动过程噪声	$q_T \times 0.05$ (扰动漂移更慢)	$[y]^2$	—	<code>qd</code>
$\mathbf{r}_v$	测量噪声	$(0.015 \cdot \text{scale})^2$	$[y]^2$	—	<code>rv</code>
$\mathbf{K}_f$	卡尔曼增益	权衡「信模型」与「信传感器」的权重向量	无量纲	$[0, 1]$	<code>k0, k1</code>
$\mathbf{S}$	新息方差	$\mathbf{S} = \mathbf{m}_{00} + \mathbf{r}_v$	$[y]^2$	> 0	<code>S</code>
ν	新息	$\nu = z - \hat{T}^-$, 观测带来的「意外信息」	同 y	小量	<code>innov</code>

2.4 系统辨识统计量

记号	中文名	物理含义	量纲 / 单位	代码变量
n	样本数	$\min(ptsRaw , ptsU)$	拍	<code>n, f.m</code>
S_{yy}	平方和	$\sum y[k]^2$	$[y]^2$	<code>Syy</code>
S_{yu}	交叉和	$\sum y[k] u[k - d]$	$[y][u]$	<code>Syu</code>
S_{y1}	一次和	$\sum y[k]$	$[y]$	<code>Sy1</code>
S_{uu}	平方和	$\sum u[k - d]^2$	$[u]^2$	<code>Suu</code>
S_{u1}	一次和	$\sum u[k - d]$	$[u]$	<code>Su1</code>

记号	中文名	物理含义	量纲 / 单位	代码变量
S_{11}	有效样本计数	参与回归的拍数	拍	<code>S11</code>
S_{yt}	交叉和	$\sum y[k] y[k+1]$	$[y]^2$	<code>Syt</code>
S_{ut}	交叉和	$\sum u[k-d] y[k+1]$	$[y][u]$	<code>Sut</code>
S_{t1}	一次和	$\sum y[k+1]$	$[y]$	<code>St1</code>
SSE	残差平方和	$\sum (y[k+1] - \hat{y}[k+1])^2$	$[y]^2$	<code>sse</code>
MSE	均方残差	SSE/S_{11} , 跨滞后可比的选型准则	$[y]^2$	<code>mse</code>
σ_u^2	输入样本方差	$S_{uu}/S_{11} - (S_{u1}/S_{11})^2$, 衡量激励强度	$[u]^2$	<code>uVar</code>
σ_u	输入标准差	$\sqrt{\sigma_u^2}$, 与量程比较判激励	$[u]$	<code>uSd</code>

辨识相关常量：

常量	值	含义
<code>IDENT_MIN</code>	12	最小样本数，少于则拒绝辨识
<code>DELAY_MAX</code>	60	纯滞后搜索上限（拍）
<code>DELAY_GAIN</code>	1.05	滞后选型容忍度（防混叠）
<code>EXC_RATIO</code>	0.01	激励门槛： $\sigma_u/uRange > 1\%$
<code>MAX_PTS</code>	600	历史环形缓冲长度
触发周期	每 20 点	新采样点累积 20 个后重新辨识

2.5 强化学习环境（MDP）变量

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
s	状态向量	$s = [\hat{T}/scale, e/scale, \Delta e/scale, \hat{d}/scale]$ ，全部无量纲	无量纲	$\approx [-5, 5]$	<code>st</code> (<code>Float64Array(4)</code>)
a	动作向量	$a = [a_u, a_p, a_i, a_d] \in \mathbb{R}^4$	无量纲	$[-1.6, 1.6]$ 实际裁剪	<code>a</code>
a_u	附加调节动作	直接叠加到 PID 输出上的偏移量	无量纲	$[-1, 1]$	<code>a[0]</code>

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
a_p, a_i, a_d	增益对数倍率	对 K_p, K_i, K_d 的乘性调整（取指数后生效）	无量纲	$[-ACT_CLIP, ACT_CLIP]$	<code>a[1..3]</code>
Δu	附加调节量	$\text{clip}(a_u, -1, 1) \cdot 0.15 \cdot uRange$	同 u	$\pm 15\%$ 量程	<code>du</code>
K_p, K_i, K_d	PID 增益	$K_p = K_{p0} e^{\text{clip}(a_p, \pm 1.6)}$, 余同	依物理	0.20 ~ 4.95 倍基准	<code>pid.kp/ki/kd</code>
r	即时奖励	代价的相反数，越大越好 (≤ 0)	无量纲	$\approx [-3, 0]$	<code>rews[]</code>
γ	折扣因子	未来奖励的现值折算率	无量纲	0.99	<code>ppoGamma</code>
ov	超调量	$\max(0, (T - SP) \cdot dir) / scale$, 只罚冲过目标的方向	无量纲	≥ 0	<code>ov</code>
$power$	功耗项	$(u /uMaxAbs)^3$, 风机水泵 $P \propto n^3$	无量纲	$[0, 1]$	<code>power</code>
w_1, w_2, w_3, w_4	奖励权重	误差 / 波动 / 超调 / 功耗 四项权重	无量纲	1.0, 0.1, 0.5, 0.3	<code>rwErr</code> 等
d_{std}	扰动强度	$\frac{distPct}{100} \cdot scale$, 每拍注入的隐藏扰动标准差	同 y	默认 2% $scale$	<code>dStd</code>
p_u	模型不确定度	域随机化幅度（对 a, b, θ 的相对扰动）	无量纲	默认 10%	<code>pu</code> (<code>modelPct/100</code>)

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
N_{steps}	推演步数	$\text{clamp}([(\theta + 5\tau) / \Delta t], 40, 300)$	拍	40 ~ 300	steps
uH	动作历史	纯滞后回放缓冲, $uH[j]$ 为第 j 拍发出的 u	同 u	—	uH
mD	生效滞后拍数	rollout 中本回合使用的滞后 (含随机化)	拍	$\approx d$	mD
mA, mB	随机化模型系数	域随机化后的 a, b	无量纲	—	mA , mB

2.6 PPO 算法变量

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
$\pi_{\theta}(a s)$	策略	状态到动作的条件分布, $a \sim \mathcal{N}(\mu(s), \sigma^2)$	概率密度	—	PpoNet
$\mu(s)$	动作均值	策略网络输出	同 a	$[-1.6, 1.6]$	网络输出
σ	动作标准差	可学习参数 (与状态无关), 控制探索幅度	同 a	$[0.02, 1.2]$	logStd 的指数
$\log \pi(a s)$	对数概率	用于重要性采样比与梯度	无量纲	负值	logp
$V(s)$	价值函数	从 s 出发的期望回报	无量纲	负 (代价)	value(st)
$Q(s, a)$	动作价值	在 s 做 a 后的期望回报	无量纲	—	不显式计算
$A(s, a)$	优势函数	$Q(s, a) - V(s)$, 动作比平均好多少	无量纲	可正可负	adv
δ_t	TD 误差	$r_t + \gamma V(s_{t+1}) - V(s_t)$	无量纲	—	delta
$\hat{A}_t^{GAE}$	广义优势	多步 TD 误差的指数加权和	无量纲	—	adv
λ	GAE 参数	偏差-一方差权衡旋钮	无量纲	0.95	ppoLam
$r_t(\theta)$	重要性采样比	$\pi_{\theta}(a s) / \pi_{\theta_{old}}(a s)$	无量纲	≈ 1	ratio
ϵ	裁剪半径	单次更新幅度上限	无量纲	0.2	ppoClip
$H[\pi]$	策略熵	探索性度量, 越大越随机	无量纲	> 0	熵项
c_{ent}	熵系数	熵奖励权重	无量纲	0.01	ppoEnt

记号	中文名	物理含义	量纲 / 单位	典型范围	代码变量
c_{vf}	价值损失系数	价值回归权重	无量纲	0.5	<code>vfCoef</code>
α	学习率	Adam 步长	无量纲	3×10^{-3}	<code>ppoLr</code>
K_{epoch}	更新轮次	每批数据复用次数	次	4	<code>ppoK</code>
B	批大小	小批量梯度下降的样本数	个	64	<code>batchSize</code>
N_{eps}	每轮轨迹数	每条回路每轮采样轨迹数	条	4	<code>ppoEps</code>
N_{iter}	迭代轮次	PPO 更新总轮数	轮	30	<code>maxIter</code>
θ_{net}	网络参数	权重与偏置 (Actor 约 400, Critic 约 300)	—	—	<code>PpoNet.w/b</code>

2.7 量纲一致性检查表

写代码或改超参时可用该表自查——左边一列必须无量纲，否则网络与滤波器会失效：

表达式	处理前量纲	归一化手法	处理后
状态各分量	$[y]$	除以 $scale$	无量纲
过程噪声 q_T	$[y]$	$(0.005 \cdot scale)^2$	与 y^2 同阶
奖励误差项	$[y]$	$ e /scale$	无量纲
附加动作 Δu	无量纲	$\times 0.15 \cdot uRange$	$[u]$
功耗项	$[u]$	$(u /uMaxAbs)^3$	无量纲
激励判据	$[u]$	$\sigma_u/uRange > 0.01$	无量纲

3. 问题定义：PID 整定到底难在哪

3.1 形式化

一条控制回路定义为三元组 (u, y, SP) （可调设备、观测设备、目标）。整定目标是找到 (Kp, Ki, Kd) 使下式最小：

$$\min_{Kp, Ki, Kd} J = w_1 \sum_k \frac{|e_k|}{scale} + w_2 \sum_k \frac{|\Delta e_k|}{scale} + w_3 \sum_k ov_k + w_4 \sum_k power_k$$

s.t. 系统稳定、不振荡、不触发设备保护


3.2 四个真实困难

1. **过程未知且时变**： τ, θ, K 随季节、负荷、设备老化变化，一次整定管不了一年。
2. **试错代价高**：在真机上「加大 Kp 看会不会振」，代价可能是超温、停机、产品报废。
3. **纯滞后致命**：允许的最大增益随 θ 增大而急剧下降。忽略 θ 的整定必然激进；经典 Ziegler–Nichols 临界比例度法本身就要求在真机上把系统调到临界振荡——工业现场基本不允许。
4. **多目标冲突**：快速跟踪（大 Kp ）vs 平稳无超调（小 Kp ）vs 节能（小动作幅度），权重只能由业务决定。

3.3 因此：真机交互必须被替代

强化学习的本质是试错学习，而工业现场恰恰**不能试错**。这就是本方案存在的全部理由。

4. 总体架构：Dyna 三路闭环



编号	环节	数据来源	频率	是否触碰真机
①	真实经验采集	真机	1 Hz	只读
②	模型学习	真机历史数据	每 20 个采样点	无
③	规划（PPO 训练）	模型	用户触发 / 定时	无
④	评估	模型	每轮训练后	无
⑤	下发	人工确认	手动	有（可回退）

关键性质：①②③④ 全程不触碰真机，正在运行的回路毫发无损。

5. 第一层：状态估计（二维增广卡尔曼滤波）

代码：`frontend/src/utils/control.js` → `createEkf2`

5.1 为什么必须先滤波

原始读数含噪声，微分项 $Kd \cdot de/dt$ 会把噪声放大成剧烈抖动；而普通低通滤波引入的相位滞后，对有纯滞后的系统是雪上加霜。卡尔曼滤波用过程模型做预测、观测做修正，抑制噪声的同时几乎不引入额外滞后。

5.2 状态定义（增广）

$$x = \begin{bmatrix} T \\ d \end{bmatrix}$$

- T : 被控量真值（去掉噪声的 y ）；
- d : 传感器测不到的未建模扰动，建模为随机游走 $d^+ = d^- + \omega_d$ ，作为第二状态一并估计。

5.3 过程模型与观测模型

$$\begin{aligned}\text{预测: } T^- &= aT^+ + bu_{eff} + c + d^+ \\ d^- &= d^+ \\ \text{观测: } z &= T + v, \quad v \sim \mathcal{N}(0, r_v)\end{aligned}$$

本模型对状态恰好是线性的，因此 EKF 退化为标准 KF：

$$F = \begin{bmatrix} a & 1 \\ 0 & 1 \end{bmatrix}, \quad H = [1 \quad 0], \quad Q = \begin{bmatrix} q_T & 0 \\ 0 & q_d \end{bmatrix}$$

5.4 五个递推步骤

① 状态预测

$$T^- = aT^+ + bu_{eff} + c + d^+, \quad d^- = d^+$$

② 协方差预测 $P^- = F P^+ F^\top + Q$

记 $P^+ = \begin{bmatrix} p_{00} & p_{01} \\ p_{10} & p_{11} \end{bmatrix}$ ，展开为：

$$\begin{aligned}m_{00} &= a^2 p_{00} + a p_{01} + a p_{10} + p_{11} + q_T \\ m_{01} &= a p_{01} + p_{11} \\ m_{10} &= a p_{10} + p_{11} \\ m_{11} &= p_{11} + q_d\end{aligned}$$

③ 新息与卡尔曼增益

$$S = m_{00} + r_v, \quad k_0 = \frac{m_{00}}{S}, \quad k_1 = \frac{m_{10}}{S}, \quad \nu = z - T^-$$

k_0 是「新息中有多少归因于 T 估计偏差」， k_1 是「有多少归因于扰动 d 」——这正是增广状态的妙处：滤波器能自动区分「测错了」和「真有扰动」。

④ 状态更新

$$T^+ = T^- + k_0 \nu, \quad d^+ = d^- + k_1 \nu$$

⑤ 协方差更新 $P^+ = (I - K_f H) P^-$

$$p_{00} = (1 - k_0) m_{00}, \quad p_{01} = p_{10} = \frac{(1 - k_0) m_{01} + (m_{10} - k_1 m_{00})}{2}, \quad p_{11} = m_{11} - k_1 m_{01}$$

p_{01}, p_{10} 取平均做对称化，防止浮点误差累积导致协方差矩阵失去对称性而发散。

5.5 噪声参数如何取

$$q_T = (0.005 \cdot scale)^2, \quad q_d = 0.05 q_T, \quad r_v = (0.015 \cdot scale)^2$$

- 比值 q_T/r_v 决定滤波器「信模型还是信传感器」： r_v 越大越信模型、曲线越平滑。
- 辨识出模型后， a, b, c 被传入 EKF；否则退化 $a = 1, b = 0, c = 0$ （纯随机游走 + 扰动估计）。
- 纯滞后同步进 EKF（见 5.6），否则 EKF 会把「滞后造成的偏差」误当成扰动。

5.6 EKF 使用滞后的操纵量

$$u_{eff} = \begin{cases} u_{now}, & d = 0 \\ ptsU[|ptsU| - d], & d > 0 \end{cases}$$

$ptsU$ 末尾是上一拍发出的 u （本拍尚未入队），故索引 $|ptsU| - d$ 恰为 d 拍前发出的动作。

6. 第二层：过程模型辨识（FOPDT）

代码： `PidControlView.vue` → `fitDelay` / `identify` / `priorModel`

6.1 为什么必须是 FOPDT 而不是纯一阶

一阶无滞后模型 $y[k+1] = ay[k] + bu[k] + c$ 的致命缺陷：它认为「动作下发，下一拍立刻见效」。若真实过程有 30 秒纯滞后，模型会低估达到稳态所需的耐心，于是：

- 训练时：策略发现「猛加 Kp 立刻降误差」→ 奖励最高 → 学到激进增益；
- 真机上：误差在滞后期间持续累积，等响应到来时已冲过头 → 振荡；
- 而模型内评估指标依然漂亮，因为模型里没有滞后。

这是基于模型强化学习最典型的翻车方式，也是本次改造的核心。

6.2 模型形式

连续域：

$$G(s) = \frac{K e^{-\theta s}}{\tau s + 1}$$

离散域（采样周期 Δt ）：

$$y[k+1] = ay[k] + bu[k-d] + c, \quad a = e^{-\Delta t/\tau}, \quad b = K(1-a), \quad \theta = d\Delta t$$

c 为工作点偏置（未建模的恒定扰动与坐标原点偏移）。

6.3 参数估计：最小二乘

对给定滞后 d ，构造回归：

$$y[k+1] = [y[k] \quad u[k-d] \quad 1] \begin{bmatrix} a \\ b \\ c \end{bmatrix} + \varepsilon_k$$

令残差平方和最小：

$$\min_{a,b,c} \sum_k (y[k+1] - ay[k] - bu[k-d] - c)^2$$

正规方程 $(X^T X)\beta = X^T y$ 展开为：

$$\begin{bmatrix} S_{yy} & S_{yu} & S_{y1} \\ S_{yu} & S_{uu} & S_{u1} \\ S_{y1} & S_{u1} & S_{11} \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} S_{yt} \\ S_{ut} \\ S_{t1} \end{bmatrix}$$

其中各累加量（对所有有效 k ）：

$$\begin{aligned} S_{yy} &= \sum y[k]^2, & S_{yu} &= \sum y[k] u[k-d], & S_{y1} &= \sum y[k] \\ S_{uu} &= \sum u[k-d]^2, & S_{u1} &= \sum u[k-d], & S_{11} &= \sum 1 \\ S_{yt} &= \sum y[k] y[k+1], & S_{ut} &= \sum u[k-d] y[k+1], & S_{t1} &= \sum y[k+1] \end{aligned}$$

实现用 3×3 高斯消元（部分选主元）求解，避免矩阵求逆的数值不稳定。

6.4 纯滞后搜索

对 $d = 0, 1, \dots, d_{max}$ 逐个拟合，按残差选型：

$$d_{max} = \min \left(60, \left\lfloor \frac{n-12}{2} \right\rfloor \right), \quad MSE(d) = \frac{SSE(d)}{S_{11}(d)}$$

- 复杂度 $O(n \cdot d_{max})$, $n = 600$, $d_{max} = 60$ 时约 3.6 万次浮点累加, 亚毫秒级, 且每 20 个采样点才执行一次;
- 必须除以样本数: 否则大滞后因样本少而天然占优。

6.5 滞后混叠与节俭原则

问题: 若激励是周期信号 (现实中设定值常被周期性调节), 滞后 θ 与 $\theta + \text{周期}$ 残差同样低, 算法会选到离谱的大滞后 (实验中真实 $\theta = 20$ 被误判为 59, 且增益符号反转)。

解决: 不取全局最优, 而取残差不显著差于全局最优的最小滞后:

$$d^* = \min \left\{ d \mid MSE(d) \leq 1.05 \cdot \min_{d'} MSE(d') \right\}$$

即: 更小的滞后只要已把误差压到接近最优 (5% 以内), 就不再增加复杂度。这同时实现了**节俭原则** (Parsimony) 与**混叠防护**。

6.6 可辨识性与激励检查

若 u 几乎不变 (PID 已稳定或人工锁定设定值), 则 $S_{uu} \approx S_{u1}^2 / S_{11}$, 正规方程退化, b (从而 K) 在数值上不可辨识——拟合出的 K 可以是任何值。因此加门槛:

$$\sigma_u = \sqrt{\frac{S_{uu}}{S_{11}} - \left(\frac{S_{u1}}{S_{11}}\right)^2}, \quad \text{要求} \quad \frac{\sigma_u}{uRange} > 0.01$$

不满足则**拒绝本次辨识**, 继续沿用先验模型, 并在 UI 明示「激励不足: 可调设备设定值几乎未变化, 增益 K 不可辨识」。宁可不用模型, 也不用错的模型。

6.7 先验模型 (保守兜底)

$$\tau = 4 \text{ s}, \quad K = \frac{0.15 \cdot scale}{uRange}, \quad \theta_0 = 2 \text{ s (用户可调)}, \quad c = y_0(1 - a) - K(1 - a)u_0$$

最后一项保证模型在**当前工作点处自洽** (代入 $y = y_0$, $u = u_0$ 时预测值等于 y_0)。保守的含义: 慢过程 + 有滞后 → 训练出的增益偏小 → 宁可慢不可振荡。

6.8 辨识结果结构

字段	含义
<code>a, b, c</code>	离散模型系数
<code>dt</code>	采样周期 (秒)
<code>delay</code>	纯滞后拍数 d
<code>theta</code>	纯滞后时间 $\theta = d \cdot dt$ (秒)
<code>tau</code>	时间常数 τ (秒)
<code>G</code>	静态增益 K
<code>n, mse, uSd</code>	样本数、均方残差、输入标准差 (诊断用)
<code>src</code>	'ident' (辨识成功) 或 'prior' (先验)

7. 第三层: 模型内环境 (rollout 推演)

代码: `PidControlView.vue` → `rollout` / `simSteps`

7.1 MDP 五元组

要素	定义
状态 s	$\left[\hat{T}/scale, e/scale, \Delta e/scale, \hat{d}/scale\right] \in \mathbb{R}^4$
动作 a	$[a_u, a_p, a_i, a_d] \in \mathbb{R}^4$
转移 P	由 FOPDT 模型决定: $T \leftarrow m_A T + m_B u_{eff} + c + d$, 含纯滞后、随机扰动、参数扰动
奖励 r	$-\left(w_1 \frac{ e }{scale} + w_2 \frac{ \Delta e }{scale} + w_3 ov + w_4 power\right)$
折扣 γ	0.99

状态四个分量分别解决什么问题：

分量	含义	没有它会怎样
$\hat{T}$	滤波后的被控量	用原始 y 会让策略学成「对噪声反应」
e	偏差 $SP - \hat{T}$	没有控制的基本驱动
Δe	偏差变化率	缺趋势信息，无法预判超调
$\hat{d}$	EKF 估计的隐藏扰动	失去预判能力 。例：此刻温度正常，但有持续热源正在加热，马上会超标——这是纯反馈控制器不具备的信息

7.2 动作到控制量的映射

$$\Delta u = \text{clip}(a_u, -1, 1) \cdot 0.15 \cdot uRange$$
$$Kp = Kp_0 e^{\text{clip}(a_p, \pm 1.6)}, \quad Ki = Ki_0 e^{\text{clip}(a_i, \pm 1.6)}, \quad Kd = Kd_0 e^{\text{clip}(a_d, \pm 1.6)}$$

两个关键设计：

- 1. **对数空间增量**： e^x 恒为正（物理意义正确），且乘性调整天然尺度不变（翻倍与减半对称）； $e^{\pm 1.6} \approx 0.20 \sim 4.95$ 倍。
- 2. **输出相对量而非绝对量**：策略只能修改 $\pm 15\%$ 动作与 $0.2 \sim 5$ 倍增益，PID 骨架始终保留。即使策略学废，最坏也只是「参数不太合适」，绝不输出危险控制量——这是安全性的第一道防线。

7.3 奖励函数（逐项）

$$power = \left(\frac{|u|}{uMaxAbs}\right)^3, \quad ov = \frac{\max(0, (T - SP) \cdot dir)}{scale}$$
$$r_k = -\left(w_1 \frac{|e_k|}{scale} + w_2 \frac{|\Delta e_k|}{scale} + w_3 ov_k + w_4 power_k\right)$$

项	默认权重	物理意义	调大的效果
$w_1 e $	1.0	跟踪精度	响应更快、更贴设定值
$w_2 \Delta e $	0.1	平稳性（抑制抖动）	动作更柔和，代价是变慢
$w_3 ov$	0.5	只惩罚越过目标的部分	显著减少超调，趋于保守
$w_4 power$	0.3	节能（相似定律 $P \propto n^3$ ）	明显降低平均转速/开度，直接降能耗

奖励恒为负（代价的相反数），因此**越大越好**（越接近 0）。

7.4 纯滞后回放

维护动作历史 uH ，每步取真正生效的历史动作：

$$u_{eff}[k] = uH[k - 1 - mD] \quad (k - 1 - mD < 0 \text{ 时取 } u_0)$$

等价于标准定义 $y[k + 1] = ay[k] + bu[k - d]$ 。滞后使误差在动作发出后一段时间内毫无改善，策略必须学会等待——这正是教给它的东西。

7.5 域随机化 (Domain Randomization)

每个采样回合开始时随机扰动模型参数：

$$m_A = \text{clip}(a(1 \pm p_u), 0.05, 0.9995), \quad m_B = b(1 \pm p_u), \quad m_D = \text{round}(d(1 \pm p_u))$$

三个要点：

1. 每回合扰动一次，不是每步。每步扰动等价于加噪声；每回合扰动才代表「模型参数本身不确定」。
2. 评估时不扰动（用名义模型），保证指标与基线可比、可复现。
3. 本质是优化最坏情况下的期望性能（鲁棒优化），而不是名义模型上的最优性能——后者工程上没有意义。

同时每拍注入隐藏扰动 $d += \mathcal{N}(0, d_{std}^2)$ （默认 2% scale），模拟传感器测不到的未建模动态。

7.6 推演时长

$$N_{steps} = \text{clamp}\left(\left\lceil \frac{\theta + 5\tau}{\Delta t} \right\rceil, 40, 300\right)$$

θ 覆盖滞后段， 5τ 覆盖约 98% 的过渡过程。若步数偏短，推演会在滞后没走完时就截断，策略会误以为「动作无效」而学出错误策略。原实现只按 5τ 计算，在有滞后时严重偏短。

8. 第四层：PPO 策略优化

代码：frontend/src/utils/rl.js（纯 JS 零依赖，含手写反向传播与 Adam）

8.1 为什么是 PPO

算法	动作空间	类型	适用性	原因
DQN	离散	异策略	不适用	PID 增益是连续量，离散化组合爆炸
DDPG / TD3	连续	确定性、异策略	一般	超参敏感、价值高估，小网络易发散
SAC	连续	随机、异策略	一般	需自动调温度系数，实现复杂
PPO	连续	随机、同策略	采用	超参鲁棒、实现简单、小样本稳定，工业界默认首选

PPO 的核心优势：用裁剪代替复杂的信任域约束，「怎么调都不会崩」，适合没有专职调参工程师的工业场景。

8.2 网络结构

$$\text{Actor: } 4 \rightarrow 16 \xrightarrow{\tanh} 16 \xrightarrow{\tanh} 4, \quad \text{Critic: } 4 \rightarrow 16 \rightarrow 16 \rightarrow 1$$

- 隐藏层 $\tanh$ ，输出层线性；
- Actor 输出高斯均值 $\mu(s)$ ；对数标准差 $\log \sigma$ 是与状态无关的可学习参数（4 维）；
- 总参数量约 800，纯 JS 单次前向/反向 < 0.1 ms。

采样与对数概率：

$$a \sim \mathcal{N}(\mu(s), \sigma^2), \quad \log \pi(a|s) = -\frac{1}{2} \left(\frac{a - \mu}{\sigma} \right)^2 - \log \sigma - \frac{1}{2} \log 2\pi$$

σ 可学习意味着探索幅度本身是学出来的：初期大 σ 广泛探索，收敛后自动缩小；代码中有 $\log \sigma \in [\log 0.02, \log 1.2]$ 的硬约束，防止探索完全消失或过大。

8.3 三个损失项

① 裁剪代理目标

$$L^{CLIP}(\theta) = \mathbb{E}_t [\min(r_t(\theta) A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t)]$$

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$$

- 当 $A > 0$ (动作优于平均)，增大其概率，但 $r > 1 + \epsilon$ 后切断梯度，防止一次更新走太远；
- 当 $A < 0$ 时同理， $r < 1 - \epsilon$ 后切断。

② 价值函数损失

$$L^{VF} = (V(s_t) - V_t^{target})^2, \quad V_t^{target} = \hat{A}_t + V(s_t)$$

③ 熵奖励

$$L^S = -\mathbb{E}[-\log \pi(a|s)] \quad (\text{最大化熵} = \text{保持探索})$$

总损失：

$$L = L^{CLIP} + c_{vf} L^{VF} - c_{ent} H[\pi]$$

8.4 GAE(λ)：优势怎么算

一步 TD 误差：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

广义优势估计把多步 TD 误差做指数加权（偏差—方差权衡）：

$$\hat{A}_t^{GAE(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

实现上从后往前递推：

$$g_t = \delta_t + \gamma \lambda g_{t+1}, \quad \hat{A}_t = g_t, \quad V_t^{target} = \hat{A}_t + V(s_t)$$

- $\lambda \rightarrow 0$ ：只用一步估计，偏差大、方差小；
- $\lambda \rightarrow 1$ ：接近蒙特卡洛全程回报，偏差小、方差大；
- 默认 $\lambda = 0.95$ 是经验最优区。

最后对优势做**标准化**（减均值、除标准差），进一步稳定更新尺度。

8.5 完整训练流程

```
1. models[i] = identify(loop_i) || priorModel(loop_i)
2. steps      = simSteps(models)                // (θ + 5τ)/dt
3. baseReward = -(零动作 rollout 的平均代价)    // 名义模型、不扰动
4. for it = 1 ... N_iter:
    trans = []
    for 每条回路 i:
        for e = 1 ... N_eps:                    // 每回合独立域随机化
            ep = rollout(agent, model_i, steps, base_i, loop_i, perturb=true)
            adv, ret = GAE(ep.rews, ep.vals, γ, λ)
            adv = standardize(adv)
            trans += zip(ep.s, ep.a, ep.logp, adv, ret)
        agent.update(trans)                      // K 轮、批大小 64、Adam
        ev = evaluate(agent, models)             // 确定性动作 + 名义模型
        best = max(best, -ev.cost)
5. 保存最佳为模型版本 (localStorage), 等待人工应用
```

8.6 超参数与调参建议

参数	默认	含义	调整建议
N_{iter} 迭代轮次	30	PPO 更新次数	收敛慢可加到 60~100
α 学习率	3e-3	Adam 步长	曲线剧烈震荡 → 降到 1e-3
ϵ 裁剪	0.2	单次更新幅度上限	想更保守 → 0.1
γ 折扣	0.99	未来奖励权重	滞后大时应更接近 1
λ GAE	0.95	优势估计偏差-方差权衡	噪声大 → 0.9
C_{ent} 熵系数	0.01	探索强度	过早收敛不动 → 0.02
K_{epoch}	4	每批数据复用次数	小数据可到 8
N_{eps} 每轮轨迹	4	每条回路每轮采样数	增到 8 更稳但更慢
σ_0 初始探索	0.4	初始动作标准差	—
$distPct$ 环境扰动	2%	隐藏噪声强度	现场噪声大 → 5%
$modelPct$ 模型不确定度	10%	域随机化幅度	模型可信度低 → 20~30%
θ_0 先验滞后	2 s	无数据时的保守滞后	按现场经验填

9. 安全落地机制

从训练到真机，共七道防线：

#	机制	作用
1	训练完全在模型内	训练期间不写任何设备，运行中的回路不受影响
2	动作为相对量	$\Delta u \leq 15\%$ 量程、增益 0.2 ~ 5 倍，PID 骨架兜底
3	纯滞后建模	防止模型低估等待时间而学出激进增益
4	域随机化	让策略对模型误差鲁棒，而非过拟合模型
5	零动作基线对比	必须与「什么都不改」比较，不比基线好就不该用
6	版本 + 一键回退	每次训练存版本 (localStorage: nengtan.agc.models.v2), 保留最近 20 个

#	机制	作用
7	人工确认才下发	输出只作为建议值展示，点「应用版本」才写入

上线建议流程：先影子模式（只算不发）跑一段时间，对比建议增益与现行增益的指标；确认有效后在小幅扰动工况试运行；最后纳入定时自动训练（支持每 1 小时 / 6 小时 / 每天）。

10. 方法选型论证：在线 / 离线 / 基于模型

原始疑问："输出动作后应该根据系统变化作出下一步决策，是不是要实时（在线）训练？"

10.1 三种范式对比

范式	反馈来源	试错成本	安全性	数据效率	结论
在线 RL（真机交互）	真机	极高（超温/停机）	差	低（实时速率）	不可用
离线 RL（历史日志）	历史数据	零	好	中	部分可用，但见下
基于模型（本方案）	辨识模型	零	好	高（可无限查询）	采用

10.2 为什么不选纯离线 RL

离线 RL（BCQ / CQL / IQL）的核心困难是**分布偏移**：历史日志里只有「旧 PID 做过的动作」，策略一旦想尝试日志外的动作，价值网络因没见过而高估，导致发散；工程上需额外的保守约束与价值惩罚，复杂且难调。本方案用**模型**替代日志：模型可对**任意**动作给出预测反馈，不存在分布偏移问题。

10.3 「在线感」的诉求其实被完全满足

诉求实质是「动作后要看到后果」。本方案满足，只是后果由模型给出：

维度	真机在线	模型内
单次反馈耗时	1 s（一个采样周期）	~1 μ s
240 步轨迹	4 分钟	~1 毫秒
一次训练（30 轮 $\times$ 4 轨迹 $\times$ ~200 步 $\approx$ 2.4 万次反馈）	约 7 小时且全程冒险	约 1 秒，零风险

反馈密度提高五个数量级，而反馈的本质（真实物理的因果）被辨识过程保留了下来。

10.4 真机反馈用在哪

用在校准模型，而不是直接训练策略：

真机(y,u) $\rightarrow$ 辨识 **FOPDT** $\rightarrow$ 模型内训练 $\rightarrow$ 评估 $\rightarrow$ 人工采纳 $\rightarrow$ 真机产生新数据 $\rightarrow$ 重新辨识

这就是 Dyna 的完整回路。真机始终是**裁判**（提供数据与最终验收），不是**陪练**（不被试错）。

10.5 什么时候才真的需要在线学习

- 过程发生**未建模的结构变化**（换设备、改工艺），且辨识跟不上；
- 强非线性（一阶线性假设失效）；
- 此时应：改用递推最小二乘（RLS）持续跟踪参数 + 小残差在线微调，**并强制限幅**。

11. 代码与文件清单

文件	职责
frontend/src/components/PidControlView.vue	视图与训练总控：采集、辨识、rollout、PPO 循环、版本管理
frontend/src/utills/rl.js	PPO 智能体：MLP、Adam、GAE、裁剪更新
frontend/src/utills/control.js	PID 控制器（条件积分抗饱和）、二维 EKF
frontend/src/i18n/en-US.js	英文词条

函数	位置	职责
fitDelay(r, dstep)	PidControlView.vue	给定滞后做最小二乘拟合并返回残差
identify(lp)	PidControlView.vue	滞后搜索 + 激励检查 → FOPDT 模型
priorModel(lp)	PidControlView.vue	先验保守模型
simSteps(models)	PidControlView.vue	推演步数 $(\theta + 5\tau)/\Delta t$
rollout(agent, m, ...)	PidControlView.vue	模型内推演，产出 (s, a, r, s')
evaluate(...)	PidControlView.vue	确定性评估 → 增益建议
startTrain()	PidControlView.vue	PPO 主训练循环
createPpoAgent	utills/rl.js	策略/价值网络与 PPO 更新
computeGae	utills/rl.js	GAE(λ) 优势与回报
createEKF2	utills/control.js	二维增广卡尔曼滤波
createPid	utills/control.js	位置式 PID + 条件积分

12. 参数速查表

12.1 辨识

常量	值	含义
IDENT_MIN	12	最小样本数
DELAY_MAX	60	滞后搜索上限（拍）
DELAY_GAIN	1.05	滞后选型容忍度
EXC_RATIO	0.01	激励门槛
MAX_PTS	600	历史缓冲长度
触发周期	每 20 点	—

12.2 滤波

常量	值	含义
FILT_Q	0.005	过程噪声系数 $\times scale$
FILT_R	0.015	测量噪声系数 $\times scale$

常量	值	含义
qd	$q_T \times 0.05$	扰动状态噪声

12.3 动作与奖励

项	值
ACT_CLIP	1.6 (增益倍率 $e^{\pm 1.6} \approx 0.20 \sim 4.95$)
Δu 上限	$\pm 15\%$ 量程
功耗指数	3
$w_1/w_2/w_3/w_4$	1.0 / 0.1 / 0.5 / 0.3

13. 验证记录

13.1 纯滞后辨识算法（合成数据，2026-09-17）

用与 rollout 完全一致的语义生成数据 ($y[k+1] = ay[k] + bu[k-d] + \epsilon$, PRBS 激励, 400 点), 校验辨识能否恢复真值:

真实 (θ, τ, K)	辨识结果	判定
(0, 8, 2.0)	$\theta = 0, \tau = 7.77 \sim 8.06, K = 1.97 \sim 2.02$	PASS
(3, 8, 2.0)	$\theta = 3, \tau = 8.03 \sim 8.09, K = 2.00$	PASS
(10, 12, 1.5)	$\theta = 10, \tau = 11.9 \sim 12.0, K = 1.49 \sim 1.51$	PASS
(20, 25, 0.6)	$\theta = 20, \tau = 21.3 \sim 27.1, K = 0.54 \sim 0.66$	PASS

- 纯滞后 θ 全部精确命中;
- τ 、 K 误差 < 15% (噪声水平下正常);
- 恒定 u 场景正确判定为「激励不足」并拒绝输出模型。

13.2 加固项有效性

加固前	加固后
周期激励下把 $\theta = 20$ 误判为 59, K 符号反转	节俭原则后精确命中 20
无激励时输出任意 K	拒绝输出并提示原因

13.3 构建

npx vite build 通过 (6.76 s), lint 0 错误, 新增词条已进入构建产物。

14. 已知局限与后续改进

局限	影响	改进方向
一阶线性假设	强非线性过程 (如 pH 中和) 拟合差	分段线性化 / 神经网络动力学 (MBPO)

局限	影响	改进方向
批量重算辨识	无遗忘机制、长序列开销	RLS + 遗忘因子，跟踪时变过程
单回路独立建模	回路间耦合未建模	MIMO 多变量辨识
无激励时无法辨识	稳态工况下模型停滞	安全限幅内注入小 PRBS 主动激励
域随机化各参数独立	未建模参数间相关性	用辨识协方差做相关采样
评估仍在模型内	模型偏差无法被评估发现	影子模式 A/B，用真机指标裁决
无稳定性硬保证	极端工况仍可能不稳	增益—相位裕度约束层（SIP）

15. 术语表（专有名词解释）

15.1 控制理论

术语	英文 / 缩写	解释
被控量	PV	被调节的物理量，本文记作 y
操纵量	MV	控制器输出动作，本文记作 u
设定值	SP	期望被控量达到的目标
偏差	error	$e = SP - PV$
比例/积分/微分增益	Kp / Ki / Kd	P 看当前误差，I 消除稳态误差，D 抑制变化趋势
积分饱和	Integral Windup	输出顶到限幅时积分项仍累加，解除后大幅超调；本实现用条件积分抑制
超调	Overshoot	被控量冲过设定值的幅度
时间常数	τ	一阶惯性响应到 63.2% 所需时间
纯滞后 / 死区时间	θ	动作发出到被控量开始响应的等待时间
静态增益	K	稳态下单位调节量引起的被控量变化
一阶加纯滞后	FOPDT	$G(s) = Ke^{-\theta s}/(\tau s + 1)$ ，工业最常用的过程近似
抗扰动能力	Disturbance Rejection	扰动出现后恢复设定值的能力

15.2 系统辨识

术语	英文	解释
系统辨识	System Identification	由输入输出数据反推模型参数的学科
最小二乘	LS	令残差平方和最小的参数估计法
正规方程	Normal Equation	$(X^T X)\beta = X^T y$
残差 / 均方残差	Residual / MSE	预测与实测之差及其均值，用于比较模型
可辨识性	Identifiability	数据是否足够「问出」某个参数
激励	Excitation	输入信号变化丰富程度；理想为 PRBS
持续激励	PE	输入须在足够长时间内含足够频率成分
滞后混叠	Delay Aliasing	周期激励下 θ 与 $\theta + \text{周期}$ 残差同样低导致误判

术语	英文	解释
节俭原则	Parsimony	同等拟合质量下优先更简单的模型
递推最小二乘	RLS	在线递推更新参数的辨识法（后续改进项）

15.3 滤波与状态估计

术语	英文	解释
卡尔曼滤波	KF	噪声中用「预测+观测」递推最优估计状态
扩展卡尔曼滤波	EKF	用雅可比局部线性化的 KF
卡尔曼增益	K_f	权衡信模型还是信传感器的权重
过程噪声	q	状态自身随机漂移强度，越小越平滑（也越滞后）
测量噪声	r	传感器不可信程度，越小越跟手（也越毛刺）
增广状态	Augmented State	把测不到的量（如扰动 d ）一并作为状态估计
随机游走	Random Walk	未知慢变量建模： $d^+ = d^- + \omega$
新息	Innovation	$z - \hat{T}^-$ ，观测带来的意外信息

15.4 强化学习

术语	英文	解释
马尔可夫决策过程	MDP	用 (S, A, P, R, γ) 描述序贯决策
策略	Policy	状态到动作的映射（本实现为高斯分布）
轨迹 / 回合	Trajectory / Episode	一串连续的 (s, a, r, s')
回报	Return	$G_t = \sum_k \gamma^k r_{t+k}$
折扣因子	γ	未来奖励现值折算率
价值函数	$V(s)$	从 s 出发的期望回报
优势函数	$A(s, a)$	$Q(s, a) - V(s)$ ，动作比平均好多少
广义优势估计	GAE(λ)	多步 TD 误差的指数加权
时序差分误差	TD Error	$\delta = r + \gamma V(s') - V(s)$
策略梯度	Policy Gradient	直接对期望回报关于策略参数求梯度
同策略 / 异策略	On/Off-policy	采样策略与目标策略是否相同
重要性采样比	ratio	π_{new}/π_{old} ，复用旧数据更新
裁剪代理目标	Clipped Surrogate	PPO 核心：把 ratio 裁到 $[1 - \epsilon, 1 + \epsilon]$
信任域	Trust Region	限制新旧策略差异（TRPO 用 KL 约束，PPO 用裁剪近似）
熵正则	Entropy Bonus	鼓励保持随机性，避免过早收敛
基线	Baseline	降方差的参照（本实现用「零动作」作性能基线）
域随机化	Domain Randomization	训练时随机扰动环境参数以鲁棒
模型偏差	Model Bias	模型与真实环境的系统性差异
离线强化学习	Offline RL	完全用历史日志训练，需处理分布偏移

附录 A：为什么「模型里的反馈」可信

模型的参数来自真机，只是把「一次真实响应」压缩成了「可重放任意次的公式」：

1. 真实世界的一次阶跃响应告诉我们「这个 u 变化会带来这个 y 变化」；
2. 最小二乘把成千上万次这样的因果关系拟合四个数 (a, b, c, d) ；
3. 有了这四个数，就能对任意 (y, u) 组合预测下一拍——这就是反馈生成器；
4. 剩余不确定性用扰动噪声与域随机化显式建模，让策略在「最坏情况」下也能工作。

类比：飞行模拟机的气动导数来自真实试飞数据，飞行员可以在里面练失速改出，而不需要拿真飞机去失速。工业 RL 同理。

附录 B：常见问题

Q：为什么训练完增益变化很小？

A：检查 UI 上的「过程模型」行是否显示 $\tau/\theta/K$ 。若显示「激励不足」，说明设定值几乎没动过，模型不可信，此时只能给出保守建议；可手动小幅改变设定值以产生激励。

Q： θ 一直是 0 正常吗？

A：若回路确实响应很快（电气量、近距离压力）则正常；若明显有输送/传导延迟却显示 0，检查采样周期 Δt 是否过大——1 s 采样无法分辨小于 1 s 的滞后，可提高采集频率到 2~5 Hz。

Q：能不能自动下发建议增益？

A：技术上可以，但不建议。当前设计为人工确认（第 7 道防线）。若要自动化，应先跑通影子模式 A/B，并加入增益—相位裕度硬约束。

Q：模型不确定度调大会怎样？

A：策略更保守（对模型误差更鲁棒），模型内指标会变差但真机更稳。建议模型可信度低（残差大、样本少）时调到 20~30%。